Пустовалова Алина (Э-2306),
Зайцев Михаил (Э-2307)

Анализ рынка недвижимости

01

Знакомство с данными

Представленный набор данных содержит информацию **о рынке недвижимости в Российской Федерации.**

1. Каждая запись в данных является *уникальным объявлением о продаже объекта недвижимости*, содержащее информацию о цене, дате публикации объявления, географическом регионе, типе здания, типе рынка (первичный/вторичный), этаже расположения объекта, общем количестве этажей в здании, числе комнат, общей площади объекта и площади кухни.
2. Исходный датасет состоит из *5 477 006 наблюдений и 9 признаков.*
3. *Наименования столбцов соответствуют общепринятым стандартам:* приведены к нижнему регистру, записаны на английском языке без использования пробелов и транслита, адекватно отражают смысл содержащихся данных.
4. *Пропуски данных обнаружены в столбце kitchen_area*. Общее количество пропущенных значений по данному признаку составляет 253 711.
5. *Было обнаружено 235.655 явных дубликатов.*
6. Проверка типов данных выявила одно несоответствие. *Столбец date*, содержащий временные метки публикации объявлений, *сохранен в строковом формате (object)* требуется его преобразование в тип datetime. Типы данных для остальных переменных определены корректно.

02

Предобработка данных

1. На начальном этапе предобработки *тип данных в столбце date был преобразован из строкового формата в тип datetime*.

2. Для упрощения количественного анализа категориальный признак *object_type был преобразован в бинарную переменную, где 1 – вторичный рынок, 0 – первичный рынок.*

Очистка и обработка переменной цена.

- Из выборки были исключены наблюдения с нулевой ценой (23 записи).
- Найденные отрицательные значения цены были интерпретированы как техническая ошибка ввода и скорректированы путем взятия их абсолютной величины (модуля).
- Обработка экстремальных значений (выбросов):
    - Первичный анализ с использованием стандартных методов (межквартильного размаха, IQR) показал наличие ~7.9% (432 534) наблюдений.
    - Учитывая несоответствие распределения цены нормальному был применен модифицированный Z-критерий. Данный метод выявил ~7.4% (405 596) экстремальных значений.
    - Массовое удаление такого объема данных нецелесообразно, так как распределение цен на рынке недвижимости характеризуется правосторонней асимметрией («тяжелым правым хвостом»), и значительная часть выявленных экстремальных значений может отражать реальную рыночную специфику, а не ошибки.
    - В качестве компромиссного решения для удаления экстремальных значений использован метод усечения по перцентилям: 0.1-го и 99.9-го (удалено 10 460 записей).
- В процессе анализа были идентифицированы записи с так называемыми «магическими ценами» (например, 999999). Подобные значения, вероятно, являются ошибочными. Для повышения качества данных такие наблюдения (870 записей) были исключены из дальнейшего рассмотрения.

Предобработка данных

4. При проверке категориального признака *building_type (тип здания) аномалий и подозрительных значений обнаружено не было.*

5. В процессе анализа признаков, описывающих этажность (level – этаж расположения объекта, levels – общее количество этажей в здании), было выявлено противоречие: *значение этажа объекта превышало общее количество этажей в здании.* Для исправления этой ошибки значения указанных столбцов были поменяны местами.

Очистка и обработка переменных площади.

- Были выявлены наблюдения, в которых *площадь кухни превышала общую площадь объекта.* Подобные записи были признаны ошибкой, и для их исправления значения в соответствующих столбцах были переставлены местами.
- Были обнаружены записи, в которых *значения общей площади и площади кухни были идентичны.* Природа возникновения таких данных не была установлена в рамках текущего набора признаков. Данные наблюдения (4 256 записей) были исключены из выборки.

- Очистка от экстремальных значений:
  - ***Общая площадь (area):*** Распределение признака содержало экстремальные выбросы, особенно в области минимальных значений. Учитывая отсутствие в данных информации, позволяющей классифицировать объекты, было принято решение об усечении выборки по значению 0.1-го перцентиля (5 442 записи).
  - ***Площадь кухни (kitchen_area):*** При анализе данного признака также были обнаружены экстремальные значения. Максимальные значения теоретически могут соответствовать объектам коммерческого назначения (например, пищевое производство). Минимальные выбросы не поддавались интерпретации, поэтому были удалены из рассмотрения по значению 0,1-го перцентиля (удалено 54 179 записей).

Предобработка данных

7. В процессе анализа количество комнат *были обнаружены отрицательные значения (-2).* Сравнительный анализ rooms = -2 и rooms = 2 не выявил статистически значимых закономерностей или сходств. В связи с невозможностью интерпретации записи с некорректным значением (172 наблюдения) были исключены из датасета.

8. *При проверке категориального признака object_type (тип рынка) аномалий и подозрительных значений обнаружено не было.*

03

Добавление информации о регионах

К исходному датасету с помощью функции merge была присоединены таблица region.csv с расшифровкой кодов регионов. Предварительно таблица была преобработана:

- Изменены названия столбцов с «code» и «reg_name» на «region» и «region_name».
- В столбце region было обнаружено составное строковое значение "7873, 6937", соответствующее записи «Республика Крым». Проанализировав данные, был сделан вывод о том, что код 7873 - г. Севастополь, а 6937 - Республика Крым.
- Тип данных в столбце «region» был изменен с типа данных object на int.

04

Восстановление пропусков

В столбце kitchen_area были обнаружены пропуски, которые мы заменили *соотношением площади кухни к общей площади в зависимости от количества комнат в квартире.*

Количество комнат

Доля кухни в общей площади

	rooms	ratio
0	-2	0.123
1	-1	0.173
2	1	0.259
3	2	0.191
4	3	0.156
5	4	0.135
6	5	0.127
7	6	0.116
8	7	0.119
9	8	0.106
10	9	0.131

05

Исследование рынка недвижимости

Величина исследования – цена за м2, поэтому изначально был создан столбец со стоимость одного квадратного метра недвижимости ***– price_per_square_meter.***

Дополнительно было обработаны аномалии по полученным данным: были устранены выбросы по значениям 0,1-го и 99,9-го перцентилей.

Динамика стоимости на рынке недвижимости

За четырехлетний период наблюдается устойчивый рост стоимости квадратного метра на рынке недвижимости РФ. Наиболее заметное ускорение темпов роста произошло в 2021 году, что свидетельствует о переходе рынка в фазу активного роста после относительной стабилизации предыдущих лет.

В 2018 году отсутствует четкий тренд: цены колеблются без выраженного роста/падения, наблюдаются резкие скачки от месяца к месяцу, средняя цена постоянно выше медианной, но разрыв непостоянный, нет ярко выраженной сезонности. Возможно, рынок находился в поиске равновесия после кризисов предыдущих лет, а также колебания могут быть вызваны малым количеством сделок.

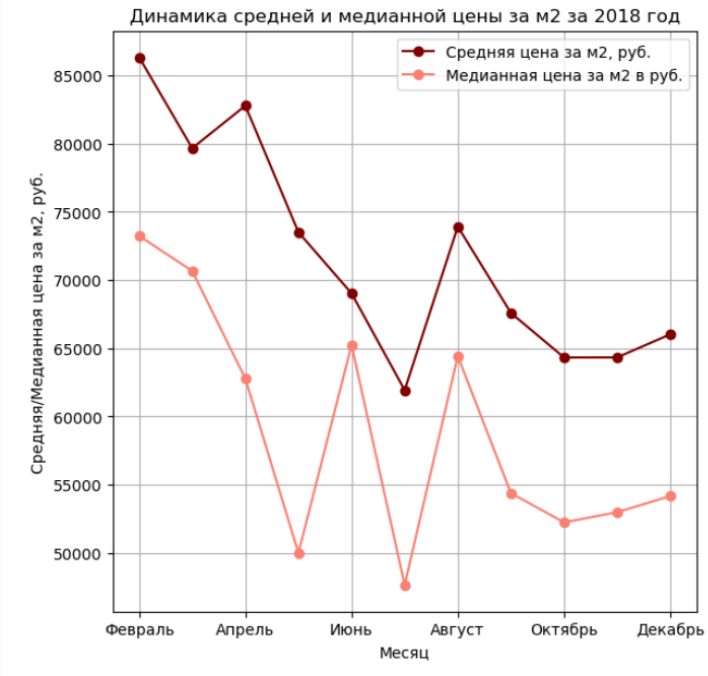

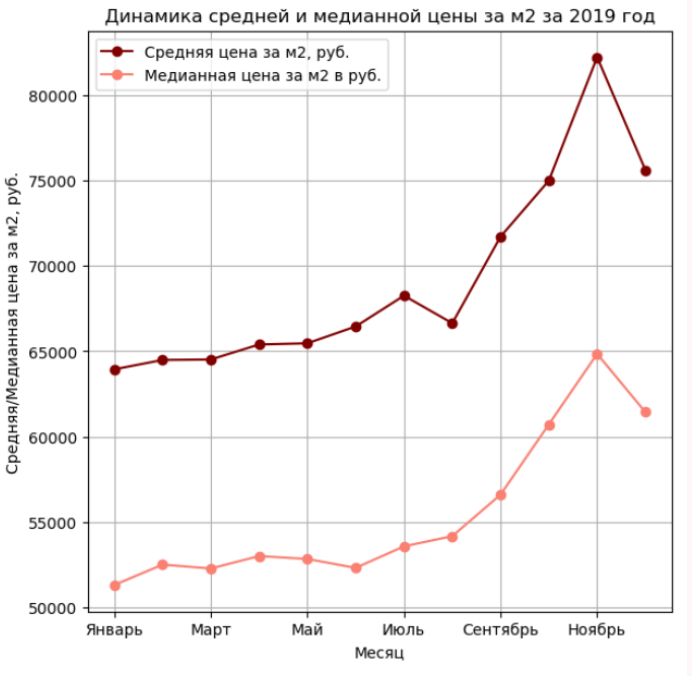

В 2019 году относительная стабильность цен: цены практически не меняются весь год (исключение резкий рост цен с августа по ноябрь), минимальный разрыв между средней и медианной ценой. Самый спокойный год из всех.

2020 год (пандемия):

- Волнообразная динамика: резкий спад весной (апрель) в следствии эффекта от пандемии, восстановление и ускорение роста во второй половине;
- Разрыв между средней и медианной ценой в 2020 году был минимальным, что указывает на повышенную однородность рынка в кризисный период — покупатели и продавцы концентрировались на "среднем" сегменте.

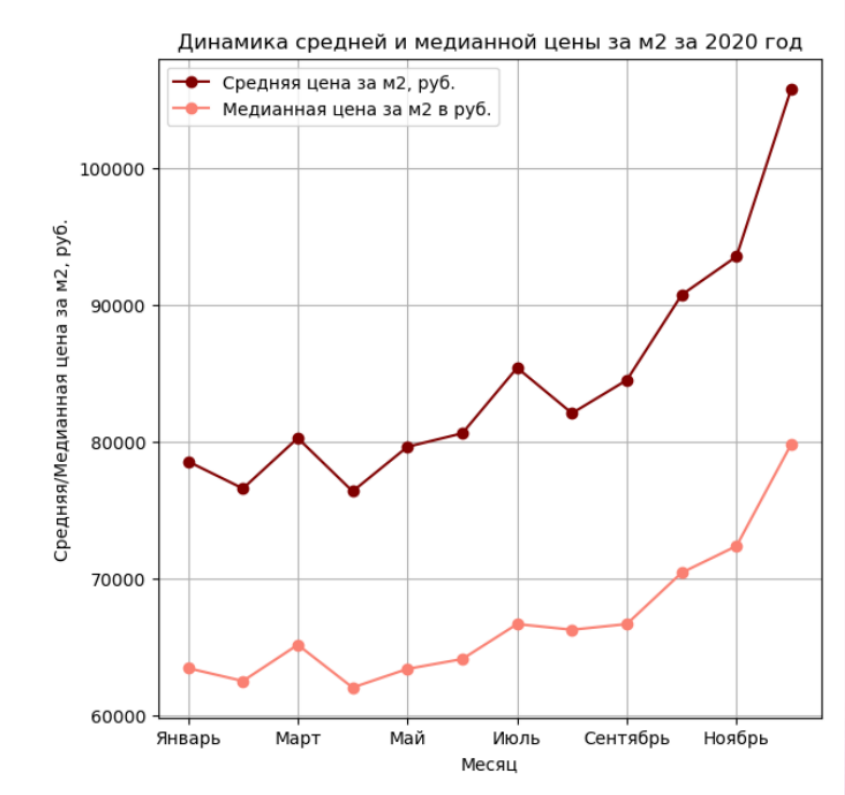

2021 год (перегрев):

- Резкий рост цены м² с января по май;
- Средняя цена растёт быстрее медианной — растёт доля дорогих объектов.

Ключевой вывод:

За рассматриваемый период цена 1 квадратного метра на рынке недвижимости увеличилась в среднем на 58%. Наиболее лучшим периодом можно считать 2019 с относительно постоянными цена, наиболее худший - это 2018 год с непостоянством цен и 2020 и 2021 года, когда начался стремительный и резкий рост цен на недвижимость.

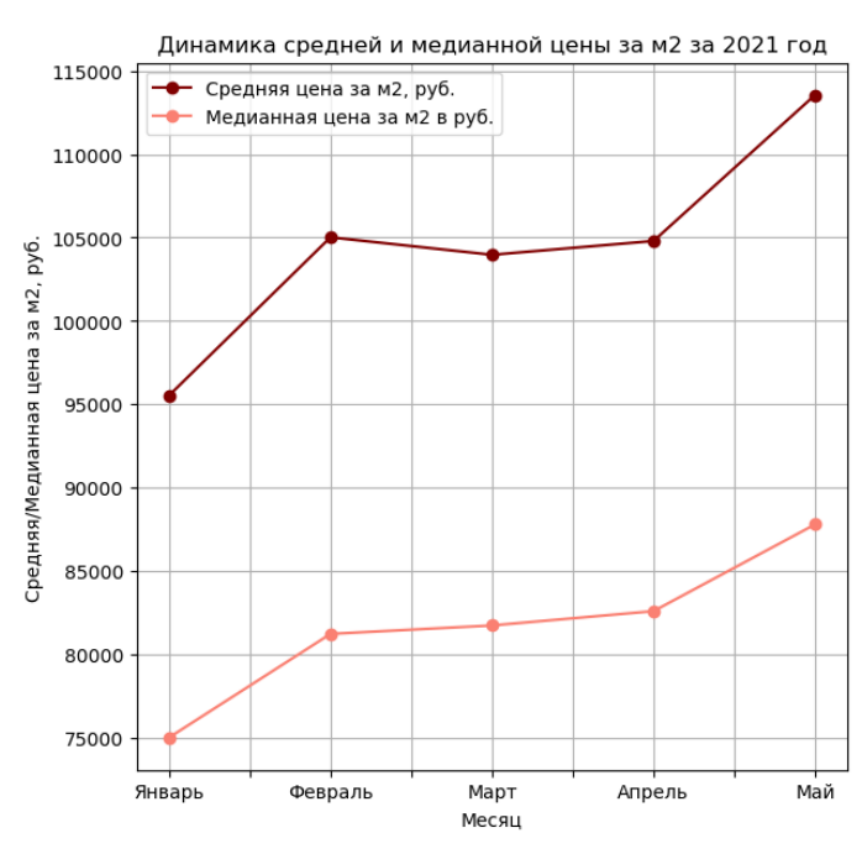

Анализ регионов

Для анализа изменения стоимости одного квадратного метра недвижимости по регионам использовались *цепные темпы прироста* стоимости по каждому региону. Далее был составлен *рейтинг 5 лидирующих регионов и 5 регионов аутсайдеров по каждому году.*

Сахалинская область показывает максимальный прирост за весь исследуемый период – около 305%. Это, вероятно, связано с масштабными экономическими факторами или эффектом очень низкой базы 2018 года. Остальные регионы из топ-5 имеют прирост в районе 30%-40%.

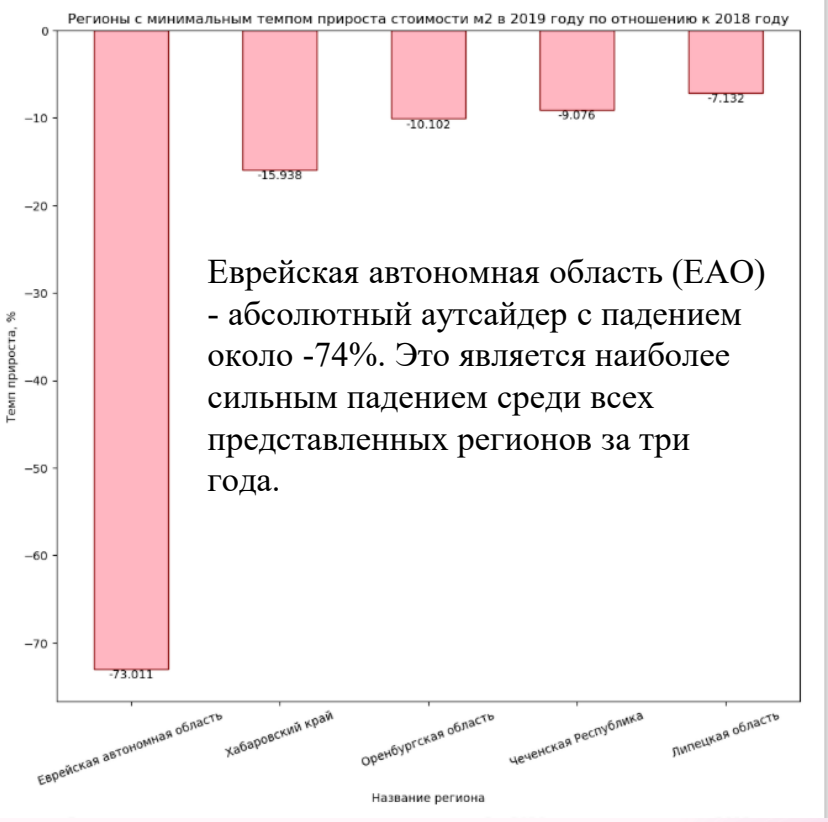

Еврейская автономная область (ЕАО) - абсолютный аутсайдер с падением около -74%. Это является наиболее сильным падением среди всех представленных регионов за три года.

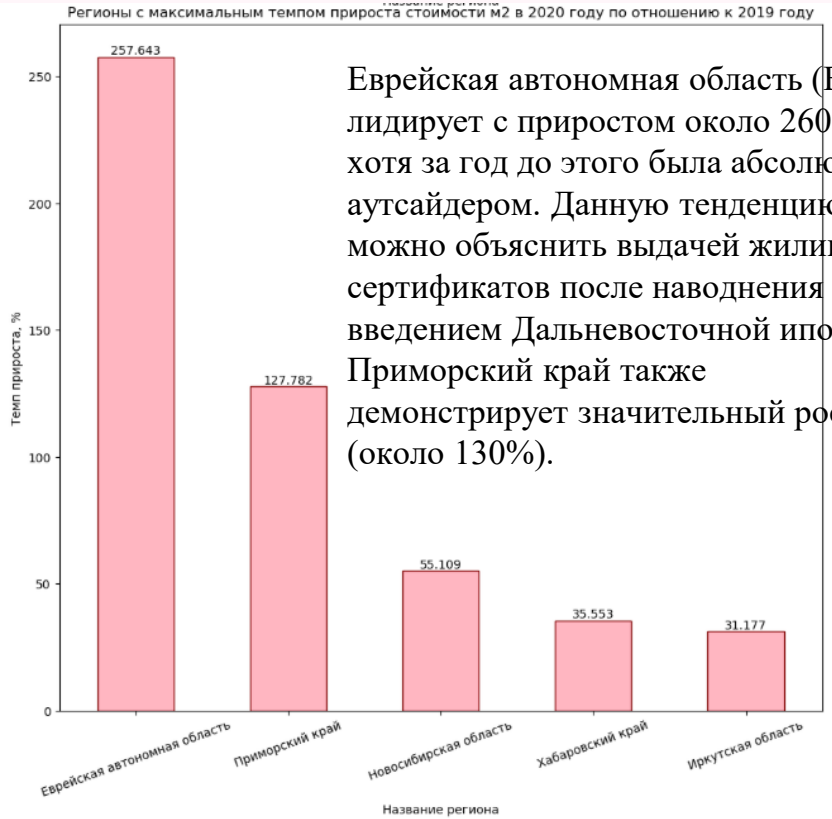

Еврейская автономная область (ЕАО) лидирует с приростом около 260%, хотя за год до этого была абсолютным аутсайдером. Данную тенденцию можно объяснить выдачей жилищных сертификатов после наводнения и введением Дальневосточной ипотеки. Приморский край также демонстрирует значительный рост (около 130%).

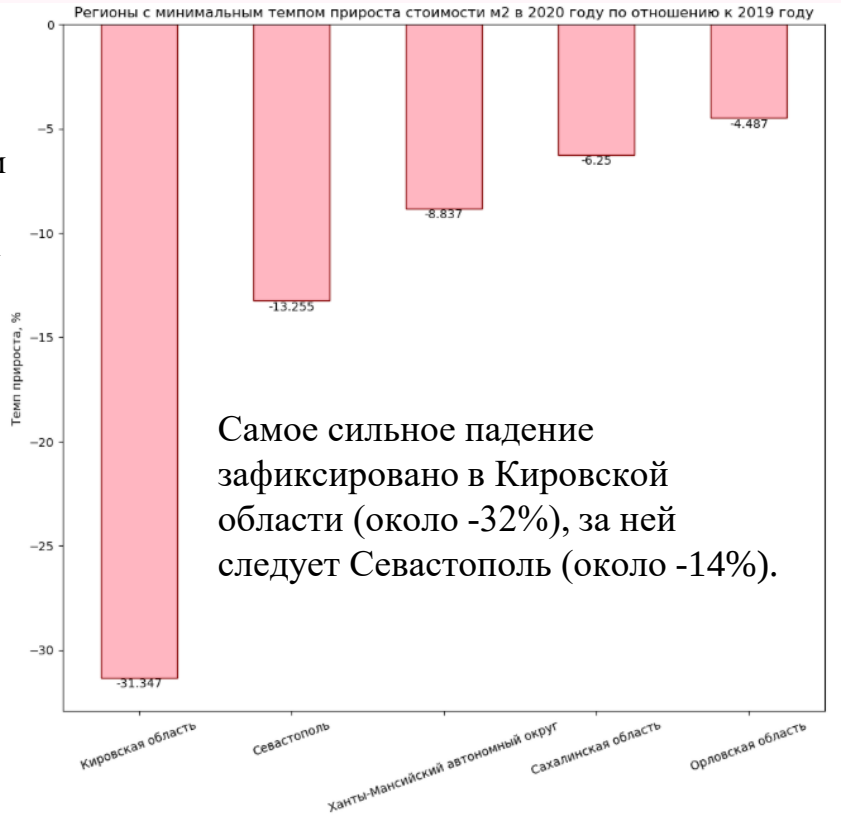

Самое сильное падение зафиксировано в Кировской области (около -32%), за ней следует Севастополь (около -14%).

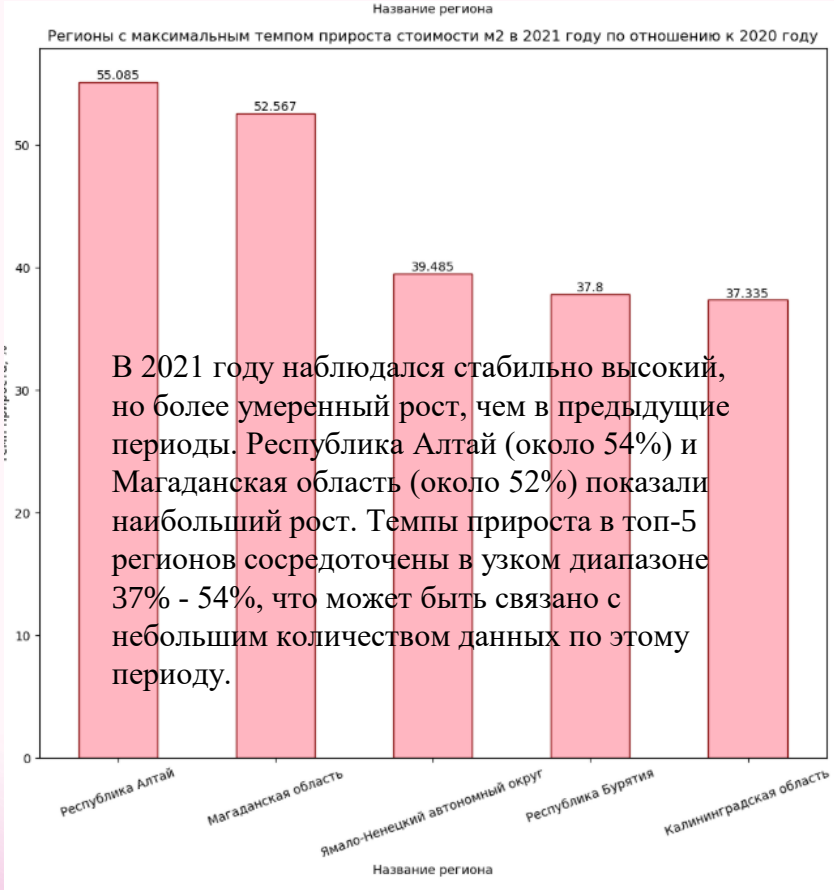

В 2021 году наблюдался стабильно высокий, но более умеренный рост, чем в предыдущие периоды. Республика Алтай (около 54%) и Магаданская область (около 52%) показали наибольший рост. Темпы прироста в топ-5 регионов сосредоточены в узком диапазоне 37% - 54%, что может быть связано с небольшим количеством данных по этому периоду.

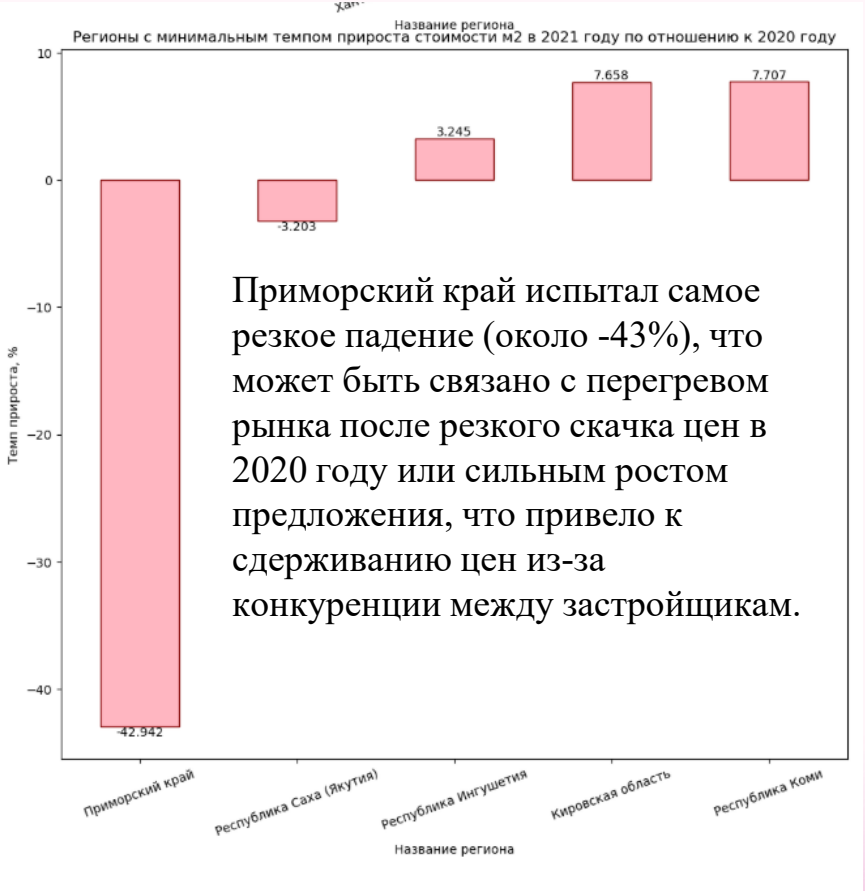

Приморский край испытал самое резкое падение (около -43%), что может быть связано с перегревом рынка после резкого скачка цен в 2020 году или сильным ростом предложения, что привело к сдерживанию цен из-за конкуренции между застройщикам.

Ключевой вывод

Регионы, такие как Еврейская автономная область (сначала -74%, затем +260%) и Приморский край (сначала +130%, затем -43%), демонстрируют крайне высокую волатильность. Рост в них часто следует за резким падением, и наоборот, что может быть индикатором нестабильного характера ценообразования.

Падения цен в некоторых регионах (до -43% в 2021 году, до -74% в 2019 году) указывают на серьезные региональные проблемы, которые могут быть связаны с оттоком населения, стагнацией экономики или переизбытком предложения.

Анализ разницы в стоимости между столицам и остальными регионами

Столицы стабильно дороже регионов в 3-4 раза. С годами данная тенденция не изменилась, а наоборот, после примерно равного разрыва в 2018 и 2019 году, в 2020 и 2021 году разрыв в стоимости увеличивается.

Анализ первичного и вторичного рынка недвижимости

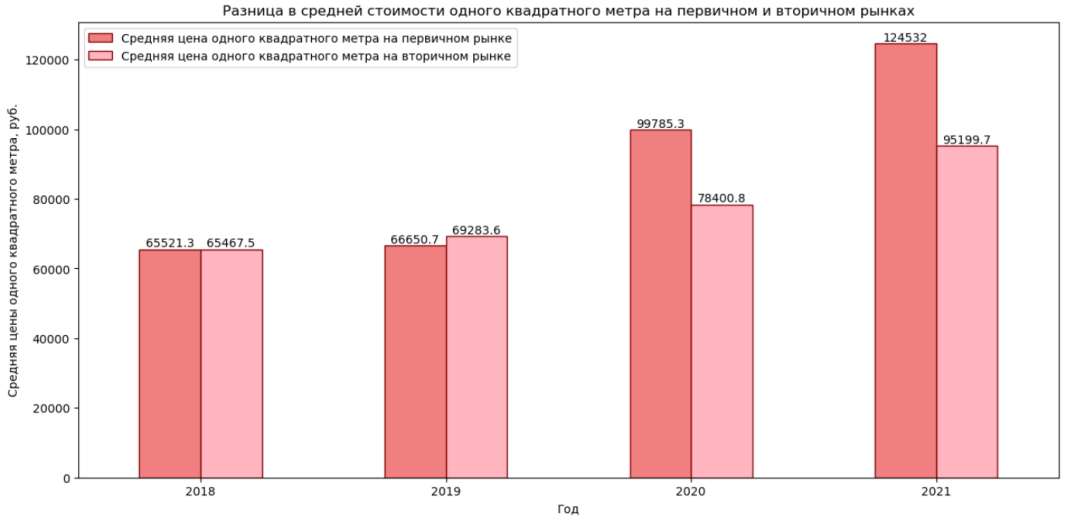

1.На обоих рынках наблюдался стабильный рост стоимости квадратного метра в течение всего периода. Максимальные значения достигнуты в 2021 году на обоих рынках.

2.Первичный рынок на протяжении всех лет демонстрирует более высокую среднюю стоимость квадратного метра по сравнению со вторичным рынком. Разрыв между рынками особенно заметен в 2020–2021 гг., где цена на первичке значительно превышает цену на вторички.

3.Первичный рынок показывает более высокие темпы роста: особенно заметен скачок с 2019 по 2020 год. Вторичный рынок растет более плавно, без резких скачков.

Анализ изменение стоимости квадратного метра недвижимости в различных сегментах рынка

Предварительно рынок был разделен на 4 группы по перцентилям:

01 7352,941 – 43000,0 – Очень дешевый сегмент

02 43000,0 – 60919,54 – Дешевый сегмент

03 60919,54 – 90909,091 – Дорогой сегмент

04 90909,091 – 500000,00 – Очень дорогой сегмент

Разница в средней стоимости одного квадратного метра на первичном и вторичном рынках для сегмента рынка

Очень дешевый сегмент

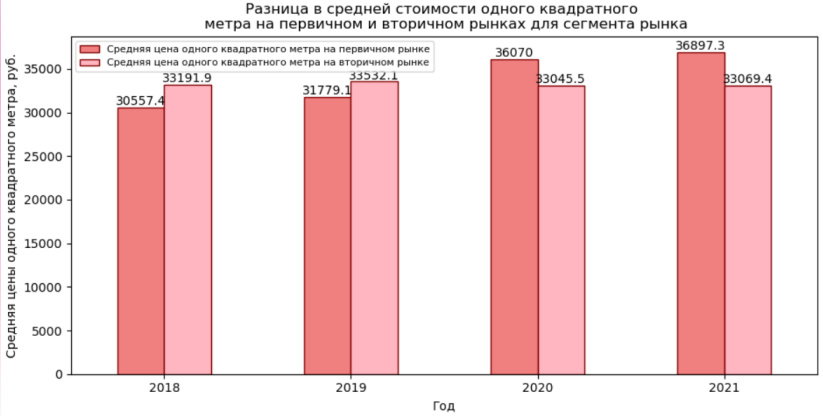

Дешевый сегмент

Дорогой сегмент

Очень дорогой сегмент

Ключевой вывод

1. В очень дешевом сегменте наблюдается минимальная динамика стоимости одного квадратного метра. В 2018 и 2019 году стоимость одного квадратного метра на вторичном рынке превышает стоимость на первичном рынке, что может объясняться тем, что в этом сегменте предложение первички часто расположено в менее развитых районах или требует длительной сдачи, тогда как вторичное жильё уже имеет хотя бы минимальную инфраструктуру. В 2020 и 2021 годах ситуация меняется в обратную сторону, что может быть связана с запуском льготной ипотеки и повышенным спросом на новостройки в условиях пандемии.
2. В дешевом сегменте также происходят минимальные изменения в динамике стоимости одного квадратного метра недвижимости. Разница в средней стоимости на первичном и вторичном рынке различается минимально.
3. В дорогом сегменте также нет динамики к росту цен по периодам. Разница в стоимости одного квадратного метра недвижимости на первичном и вторичном рынке различается минимально, что связано с тем, что покупатели дорогого жилья часто ориентируются на конкретные параметры (локация, качество, инфраструктура), а не на тип рынка.
4. В очень дорогом сегменте наблюдается рост стоимости одного квадратного метра недвижимости. Рост цен в 2020–2021 годах на первичном рынке особенно заметен — это связано с трендом на премиальное жильё с улучшенными планировками, технологиями и услугами. Инвесторы и состоятельные покупатели в кризисные периоды часто переводят средства в недвижимость как в защитный актив, что поддерживает спрос на новое элитное жильё.

Анализ динамики стоимости одного квадратного метра в зависимости от типа дома

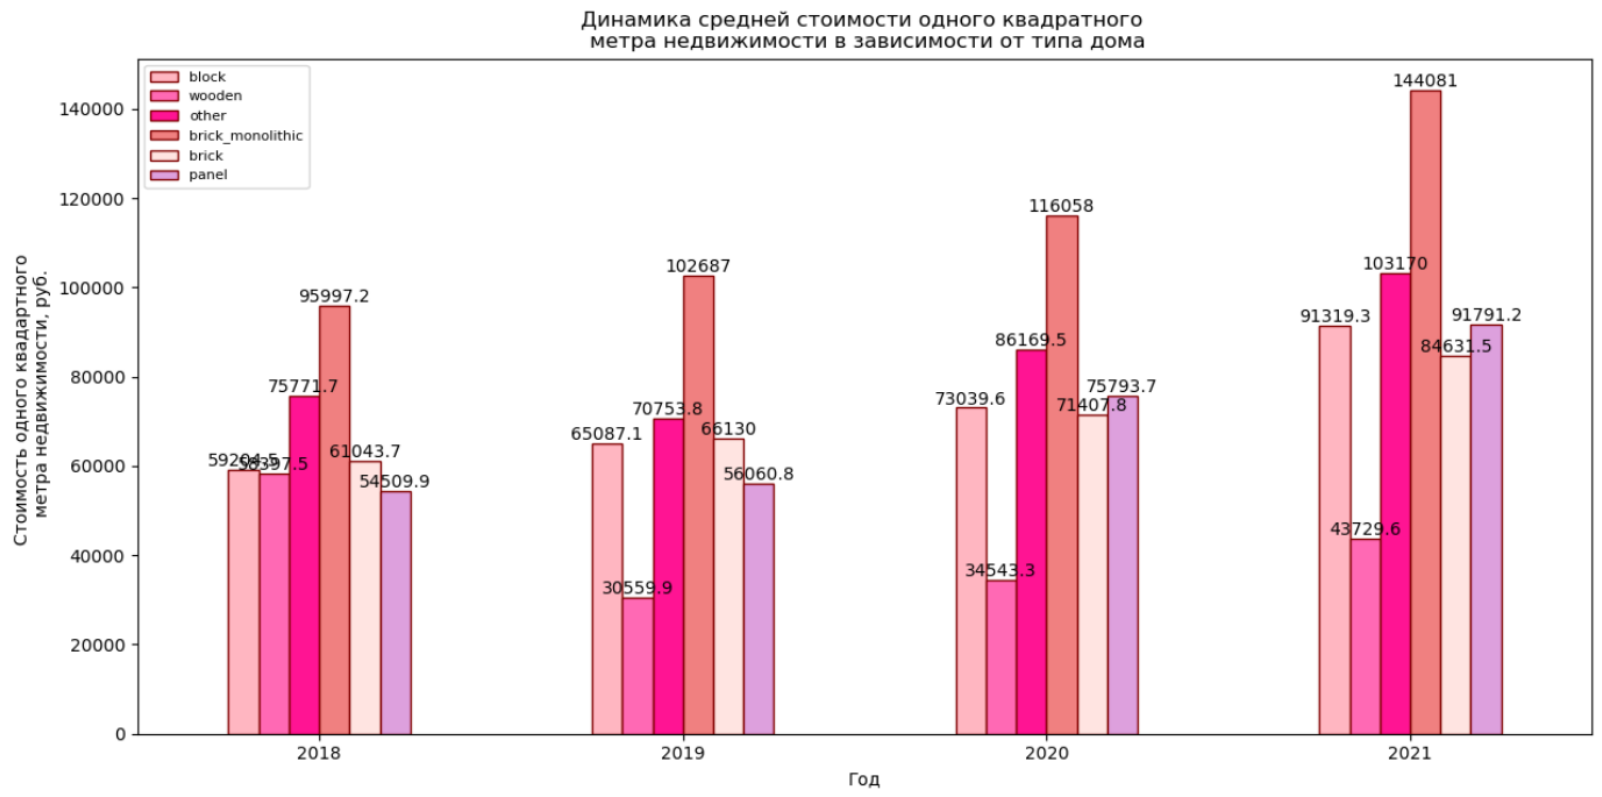

Ключевой вывод

За четыре года наблюдается устойчивый рост стоимости квадратного метра во всех категориях жилья. Это указывает на общий рост цен на рынке недвижимости. В рассматриваемом периоде самый дорогой тип жилья – кирпично-монолитный (прирост в стоимости составил 50,09% за весь период). Следующим стабильным лидером каждого года стал тип «другое» (общий прирост 36%). На протяжении всего рассматриваемого периода сохраняется спрос на современные, технологичные и престижные решения.

В 2018 году наиболее дешевыми являются панельные дома. Блочные, деревянные и кирпичные типы недвижимости примерно равны в средней стоимости.

В 2019 году наиболее дешевым становится деревянное жилье, которое остается аутсайдером по стоимости весь оставшийся период.

За рассматриваемый период наблюдается существенный рост стоимости панельных (68,39%), кирпичных (38,64%) и блочных (54,244%) домов. Наблюдается интенсивный рост спроса на доступное жильё, который, вероятно, подогревался государственными программами (льготная ипотека).
Темпы прироста стоимости деревянного жилья, наоборот, сокращаются на 25,117%. Снижение стоимости говорит либо о сокращении спроса (возможно, из-за восприятия меньшей долговечности, пожароопасности), либо о выбытии таких объектов из активного рыночного оборота.

06

Когда выгодно покупать/продавать объект недвижимости

На наш взгляд, для анализа того, когда выгодно покупать и продавать объект недвижимости, нужно проанализировать сезонность и зависимость стоимости недвижимости от различных факторов, например, ключевая ставка, изменения в законодательстве и т.д. Т.е. не во всех случаях повышение цены будет свидетельствовать о том, что сейчас выгодно продавать недвижимость.

Анализ динамики средней стоимости квадратного метра недвижимости

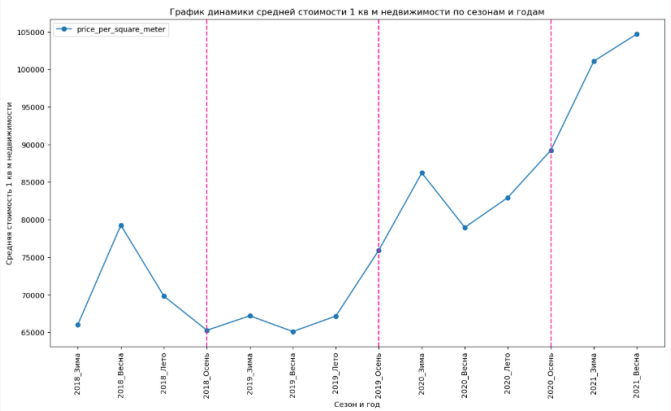

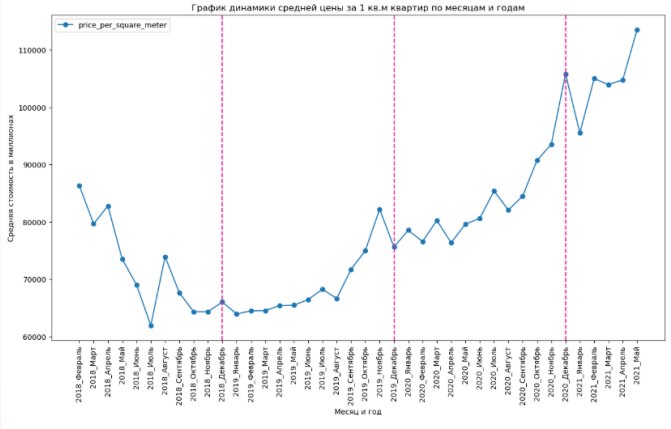

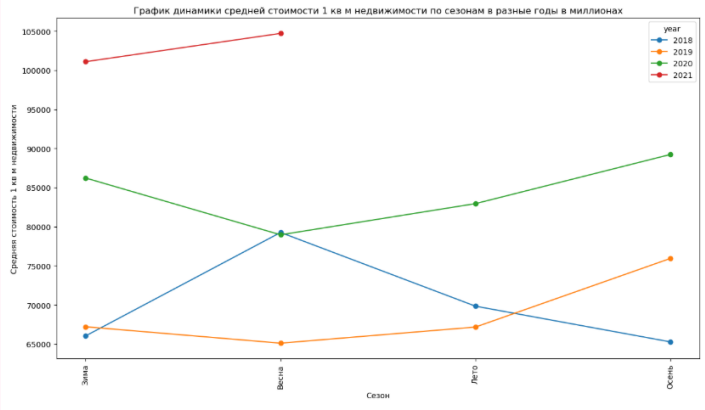

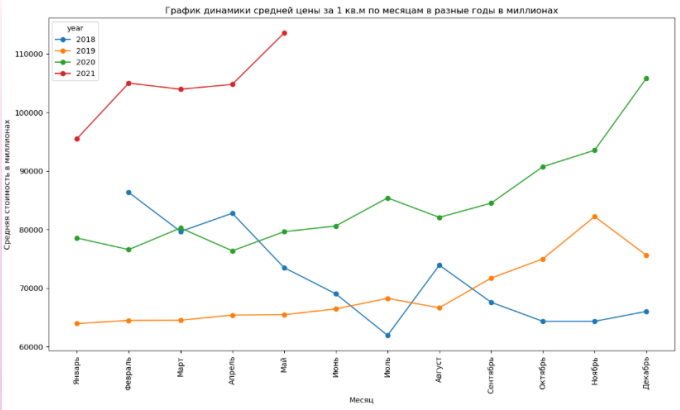

Добавим к анализу сезонность величину ключевой ставки Российской Федерации

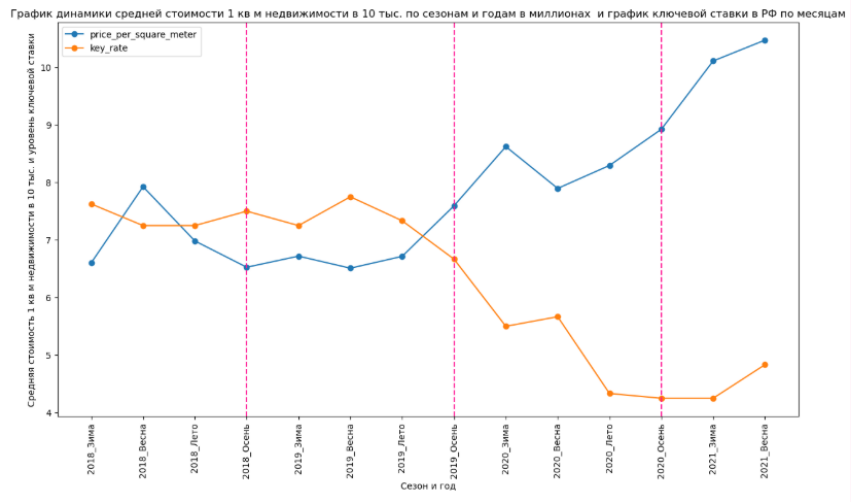

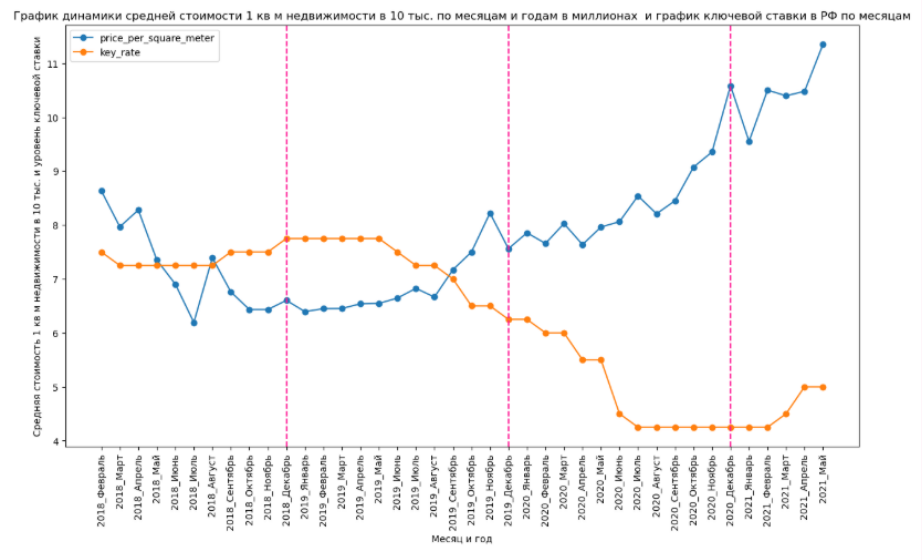

Ключевой вывод

1. Если объект недвижимости продается с целью покупки нового, более дорогого объекта недвижимости, то продавать выгодно тогда, когда цены ниже. Т.е. в периоды, когда ключевая ставка высокая (при покупке без использования ипотеки). Т.к. новый объект недвижимости будет дороже на меньшую сумму, чем при низкой ставке. При рассмотрении сезонности, в таком случае выгоднее продавать недвижимость скорее в летний сезон, когда во все годы цены снижались.
2. При продаже с целью получения наличных денег, выгоднее всего продавать, когда ключевая ставка низкая, в эти периоды цены на недвижимость растут, т.е. вы получите большую сумму наличных денег. При рассмотрении сезонности, в таком случае выгоднее продавать недвижимость скорее в зимний или осенний сезон (ноябрь - декабрь).
3. При покупке недвижимости вне зависимости от того, на какие деньги она будет куплена, выгоднее всего покупать в летний сезон.
4. При покупке за наличные деньги выгоднее покупать недвижимость в периоды, когда ключевая ставка высокая, т.к. цены в этот период ниже.

При покупке в ипотеку однозначный ответ дать нельзя. Мы видим несколько моделей поведения:

- Покупка квартиры в ипотеку при высокой ключевой ставке за меньшую сумму, но с большим процентом с расчётом на то, что в будущем будет сделано рефинансирование. В такой модели появляются риски, связанные с неизвестностью о том, когда понизят ставку ЦБ и о том, сделают ли вам рефинансирование.
- Покупка квартиры в период низкой ключевой ставки за большую сумму, но с меньшим процентом. В данном случае нет рисков, связанных с ожиданием понижения ставки ЦБ и решением о рефинансировании.

07

Определение признаков, от которых зависит стоимость объекта недвижимости

Рассмотрим зависимость стоимости объекта недвижимости и стоимости одного квадратного метра недвижимости от количественных переменных

Зависимости стоимости объекта недвижимости

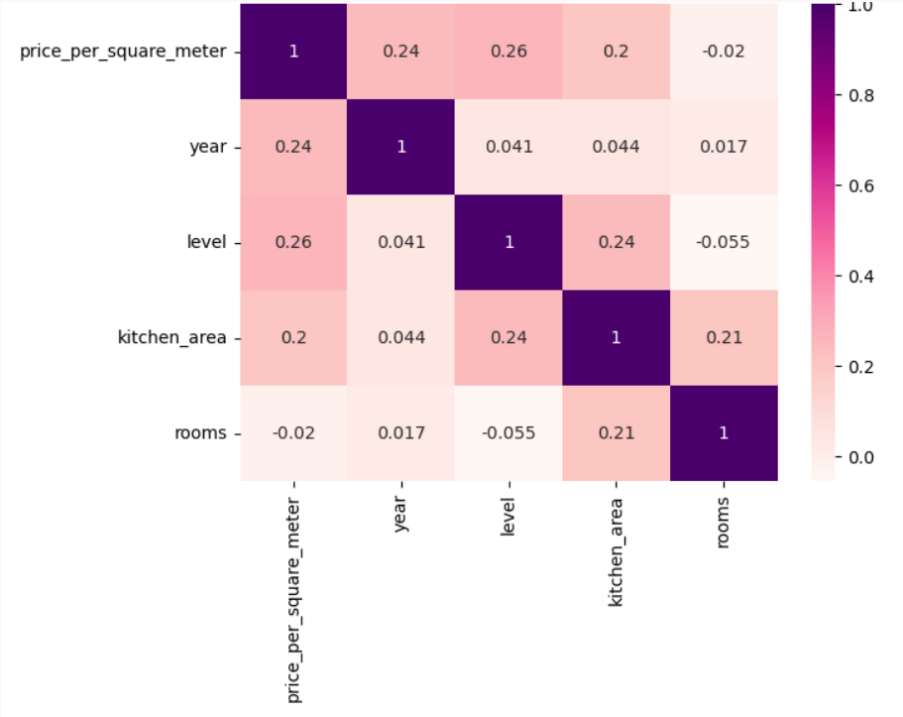

Зависимости стоимости одного квадратного метра объекта недвижимости

Рассмотрим зависимость стоимости объекта недвижимости и стоимости одного квадратного метра недвижимости от категориальных переменных

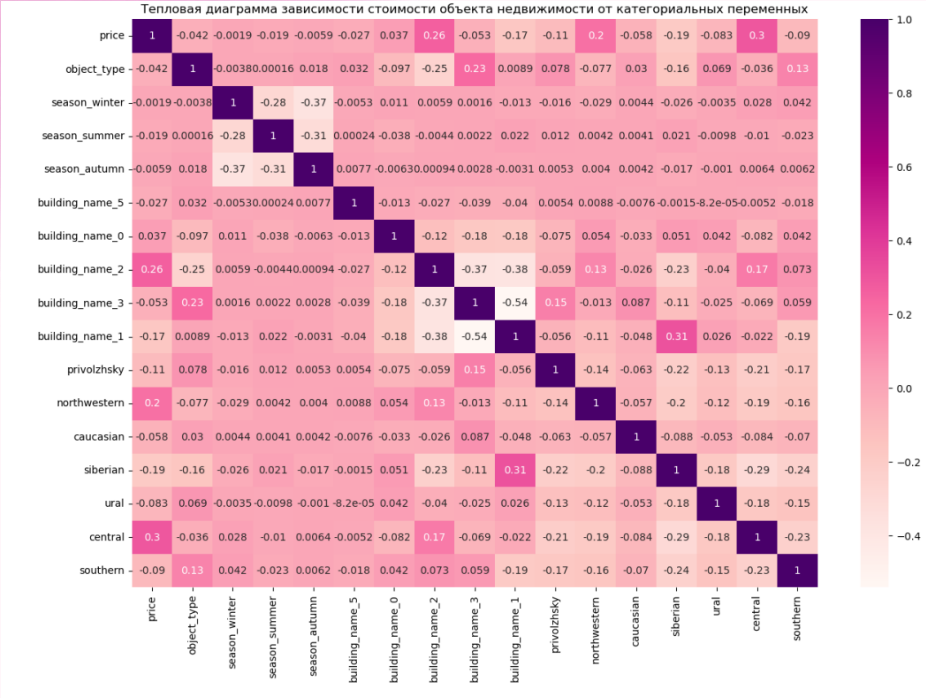

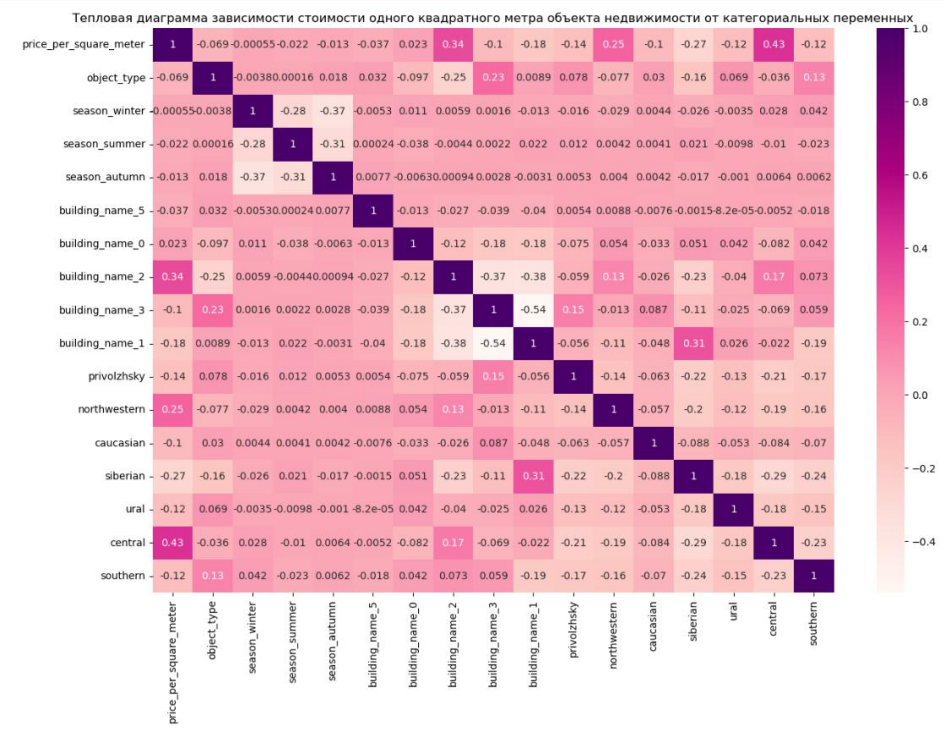

Вывод о взаимосвязи стоимости объекта недвижимости с другими признаками

Заметная/Умеренная положительная связь

- price и area (коэффициент корреляции 0.51), следовательно, увеличение общей площади объекта существенно влияет на рост его стоимости.
- price и kitchen_area (0.45) и price и rooms (0.4), следовательно, стоимость также зависит от площади кухни и количества комнат.
- central (коэффициент 0.295) и northwestern (0.202), следовательно объекты, расположенные в Центральном и Северо-Западном федеральных округах, статистически значимо дороже.

Слабая положительная связь

- price и level (0.26) и price и year (0.21), следовательно, этаж и год размещения объявления имеют незначительное влияние на стоимость.
- Кирпично-монолитные дома имеют слабую положительную связь, что может говорить о престижности или особенностях этого типа застройки.

Отрицательная связь

- С Сибирским (-0.190), Южным (-0.090), Приволжским (-0.106), Уральский (-0.083), Северо-Кавказский (-0.058) федеральными округами. Это указывает на более низкую стоимость недвижимости в этих округах по сравнению со средним уровнем.
- Панельные (-0.172) и кирпичные (-0.053) дома показывают отрицательную корреляцию, что может указывать на менее востребованные варианты.
- Все сезоны имеют очень слабую отрицательную корреляцию с ценой (от -0.001 до -0.019).
- Коэффициент -0.042 указывает на крайне слабую отрицательную связь между стоимостью объекта недвижимости и рынком (первичный/вторичный).

Вывод о взаимосвязи стоимости одного квадратного метра объекта недвижимости с другими признаками

Заметная/Умеренная положительная связь

- central (0.433) и northwestern (0.248). Это означает, что цена за м² значительно выше в Центральном и Северо-Западном округах.
- Кирпично-монолитный тип дома имеет сильную положительную связь (0.337), что может говорить о премиальности или высокой стоимости квадратного метра в таких домах.

Слабая положительная связь

- level (0.26) — слабая положительная связь (этаж немного влияет на цену м2).
- year (0.24) — слабая положительная связь.
- kitchen_area (0.20) — очень слабая положительная связь.
- rooms (-0.02) — связь практически отсутствует.

Отрицательная связь

- Сильная отрицательная связь — Сибирский (-0.266), Приволжский (-0.137), Южный (-0.118), Уральский (-0.119), Северно-Кавказский (-0.100) федеральные округа. Это указывает на более низкую стоимость квадратного метра в этих регионах.
- Панельный (-0.178) и кирпичный (-0.104) тип домов показывают отрицательное влияние на цену за м2.
- Сезоны и тип рынка (первичный/вторичный рынок) имеют очень слабые корреляции (близкие к нулю), что говорит о их незначимости для цены за м2.

08

Проверка гипотез статистическими методами

Проверка гипотез статистическими методами

t-тест по выборке очищенной от выбросов

Летом средняя стоимость недвижимости ниже, чем осенью и в декабре

Исходя из результатов теста, действительно, осенью и в декабре цены выше, чем летом. Можно сказать, что к новому году цены на недвижимость растут, а летом наблюдается спад.

Средние цены на недвижимость в Центральном ФО и в Северо-Западном ФО выше, чем в других ФО

Исходя из результатов теста, действительно, цены на недвижимость в центральном ФО и в Северо-западном ФО выше, чем в других ФО. Это связано с тем, что в данных ФО находятся столицы России: Москва и Санкт-Петербург.

Проверка гипотез статистическими методами

t-тест по выборке очищенной от выбросов

Средняя стоимость недвижимости на первичном рынке выше чем на вторичном

Статистически значимые различия в стоимости недвижимости на первичном и вторично рынке есть. Рассмотри отдельно в каком направлении.

Средняя стоимость недвижимости на первичном рынке за представленный период выше, чем на вторичный. Это, возможно, связано с введением льготной ипотеки на первичное жилье и введением системы эскроу-счетов (были введены в середине 2019 года, но повлияли на цену только с 2020 года).

09

Создание модели прогноза цены объекта недвижимости

Факторы, от которых зависит цена объекта недвижимости

1. Площадь
2. Площадь кухни
3. Количество комнат
4. Тип дома
5. Тип рынка
6. Регион расположения объекта
7. Сезон
8. Ключевая ставка

Модель

Фиктивная переменная – количество комнат

$$y = 11{,}245 + 0{,}0096x_1 - 0{,}046x_2 - 0{,}105x_3 - 0{,}125x_4 - 0{,}0675x_5 - 0{,}023x_6 - 0{,}007x_7 - 0{,}00298x_8 - 0{,}0047x_9 - 0{,}0014x_{10} + 0{,}169x_{11} - 0{,}051x_{12} + 0{,}054x_{13} - 0{,}066x_{14} - 0{,}17x_{15} - 0{,}039x_{16} + 0{,}175x_{17} - 0{,}007x_{18} + 0{,}0067x_{19} + 0, x_{20} + 0, x_{21} - 0{,}03x_{22} + e$$

*Region_million * object_type*

Города-миллионники

Центральный ФО

Сезоны

Тип дома
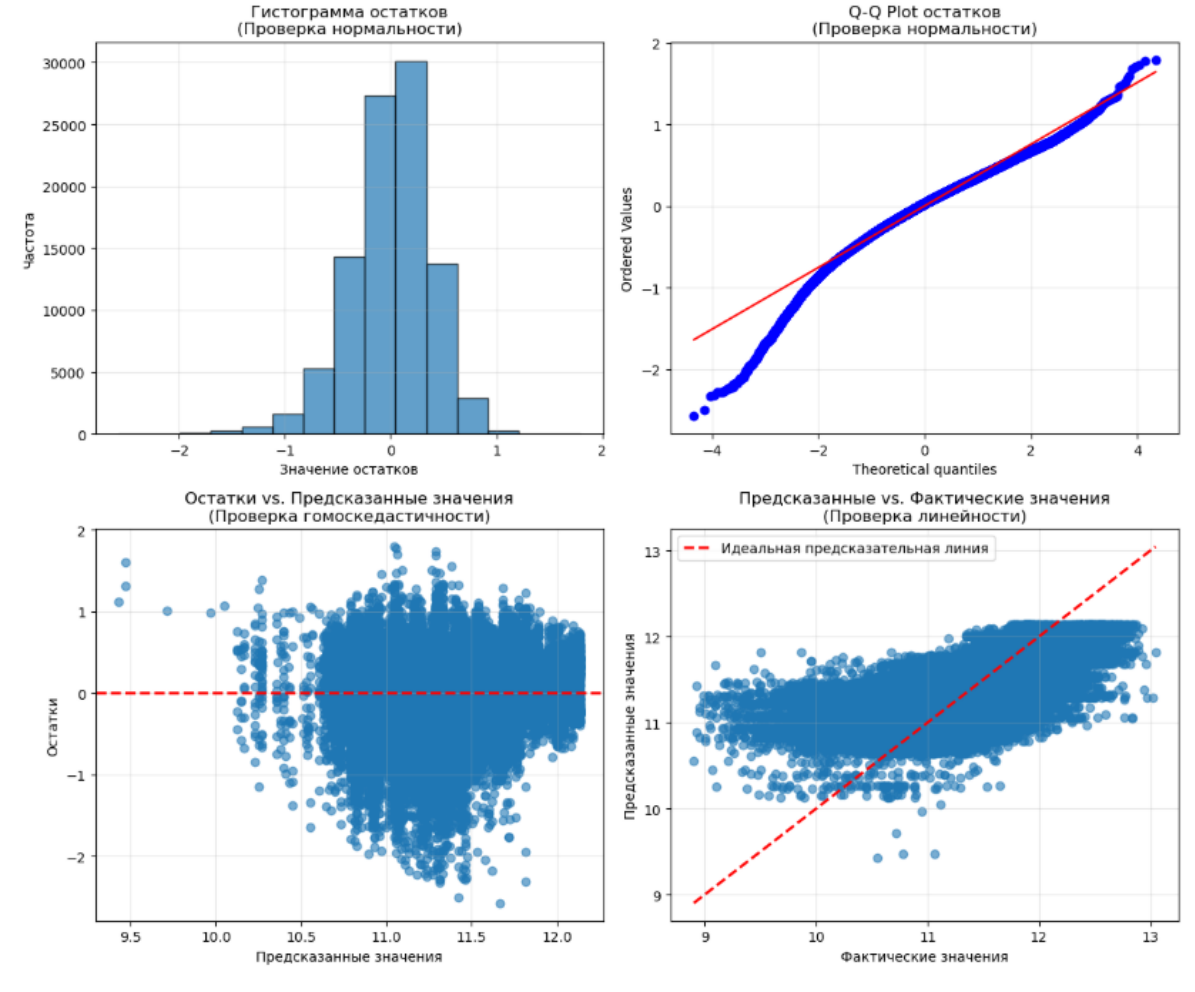
Проверка модели